

# I METODI DI DISCESA

## 1. Generalità sui metodi di discesa

Per la risoluzione di un sistema lineare  $Ax = b$  con matrice  $A$  reale, simmetrica e definita positiva, un'altra famiglia di metodi iterativi è data dai così detti *metodi di discesa*.

**Nota:** Ricordiamo che dati due vettori colonna  $x, y \in R^n$  con la notazione  $\langle x, y \rangle$  si intende il prodotto scalare  $x^T y$ .

Il risultato teorico alla base di questi metodi è il seguente:

### Teorema 1:

Sia  $A \in R^{n \times n}$ , matrice simmetrica e definita positiva,  $b, x \in R^n$ , allora la soluzione del sistema lineare

$$Ax = b \quad (1)$$

coincide con il punto di minimo della seguente funzione quadratica

$$F(x) = \frac{1}{2} \langle Ax, x \rangle - \langle b, x \rangle = \frac{1}{2} x^T A x - b^T x = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j - \sum_{i=1}^n b_i x_i \quad (2)$$

ove la forma quadratica

$$Q(x) = \langle Ax, x \rangle = x^T A x \text{ è positiva per } x \neq 0.$$

Il teorema afferma quindi che risolvere il sistema (1) equivale a minimizzare la funzione (2).

### Dimostrazione:

Se consideriamo il sistema (1) e definiamo il vettore residuo

$$r = Ax - b$$

se  $x^*$  è la soluzione del sistema (1), allora  $r = Ax^* - b = 0$ .

Ora consideriamo la funzione quadratica:

$$F(x) = \frac{1}{2}x^T A x - b^T x = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j - \sum_{i=1}^n b_i x_i$$

e cerchiamo il suo punto di minimo.

A questo scopo calcoliamo il gradiente di  $F$  ed uguagliamolo a zero:

$$\nabla f = \begin{bmatrix} \frac{\partial F}{\partial x_1} \\ \frac{\partial F}{\partial x_2} \\ \vdots \\ \frac{\partial F}{\partial x_n} \end{bmatrix}$$

Sviluppiamo  $F(x)$

$$\begin{aligned} F(x) &= \frac{1}{2} (a_{11}x_1^2 + a_{12}x_1x_2 + \cdots + a_{1i}x_1x_i + \cdots + a_{1n}x_1x_n + \\ &+ a_{21}x_2x_1 + a_{22}x_2^2 + \cdots + a_{2i}x_2x_i + \cdots + a_{2n}x_2x_n + \\ &\cdots \\ &+ a_{i1}x_ix_1 + a_{i2}x_ix_2 + \cdots + a_{ii}x_i^2 + \cdots + a_{in}x_ix_n + \\ &\cdots \\ &+ a_{n1}x_nx_1 + a_{n2}x_nx_2 + \cdots + a_{ni}x_nx_i + \cdots + a_{nn}x_n^2) - (b_1x_1 + b_2x_2 + \cdots + \\ &b_nx_n) + \\ \frac{\partial F}{\partial x_1} &= \frac{1}{2} (2 a_{11}x_1 + a_{12}x_2 + a_{1i}x_i + \cdots + a_{1n}x_n + a_{21}x_2 + a_{i1}x_i + \cdots a_{n1}x_n) - b_1 \end{aligned}$$

Per ipotesi la matrice  $A$  è simmetrica quindi  $a_{ij} = a_{ji}$ , quindi la precedente relazione si può semplificare in:

$$\frac{\partial F}{\partial x_1} = \frac{1}{2} (2 a_{11}x_1 + 2a_{12}x_2 + 2a_{1i}x_i + \cdots + 2a_{1n}x_n) - b_1$$

cioè

$$\frac{\partial F}{\partial x_1} = a_{11}x_1 + a_{12}x_2 + a_{1i}x_i + \dots + a_{1n}x_n - b_1$$

Analogamente si ricava che

$$\frac{\partial F}{\partial x_i} = a_{i1}x_1 + a_{i2}x_2 + a_{ii}x_i + \dots + a_{in}x_n - b_i \quad i=1,\dots,n$$

che si può scrivere come

$$\frac{\partial F}{\partial x_i} = \sum_{j=1}^n a_{ij}x_j - b_i = 0 \quad i = 1, \dots, n$$

e, in termini vettoriali,

$$\nabla F = Ax - b$$

*Poiché abbiamo definito  $r = Ax - b$ , risulta che il vettore che annulla il gradiente coincide con la soluzione del sistema lineare, che rende nullo il residuo.*

$$r = \nabla F = Ax^* - b = 0.$$

Verifichiamo che il punto che annulla il gradiente è effettivamente un punto di minimo. A tale scopo calcoliamo la matrice Hessiana H di F:

$$H_F(x, y) = \begin{bmatrix} \frac{\partial^2 F}{\partial x_1^2} & \frac{\partial^2 F}{\partial x_1 \partial x_2} & \dots & \dots & \frac{\partial^2 F}{\partial x_1 \partial x_n} \\ \frac{\partial^2 F}{\partial x_2 \partial x_1} & \frac{\partial^2 F}{\partial x_2^2} & & & \frac{\partial^2 F}{\partial x_2 \partial x_n} \\ & & \dots & & \\ \frac{\partial^2 F}{\partial x_n \partial x_1} & \frac{\partial^2 F}{\partial x_n \partial x_2} & & \dots & \frac{\partial^2 F}{\partial x_n^2} \end{bmatrix}$$

Osserviamo che, poiché

$$\frac{\partial F}{\partial x_i} = a_{i1}x_1 + a_{i2}x_2 + a_{ii}x_i + \dots + a_{in}x_n - b_i$$

si ha

$$\frac{\partial F}{\partial x_i \partial x_j} = a_{ij} \quad \text{e quindi} \quad H_F(x, y) = A$$

Risulta

$$H_F(x, y) = \begin{bmatrix} a_{11} & a_{12} & \dots & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & \dots & a_{2n} \\ \dots & & & & \\ \dots & & & & \\ a_{n1} & a_{n2} & \dots & \dots & a_{nn} \end{bmatrix}$$

La matrice Hessiana coincide con la matrice A che ha determinate maggiore di zero, ed elemento  $a_{11} > 0$  essendo definita positiva.

**Vale infatti il Criterio di Sylvester** per le matrici simmetriche e definite positive.

Il criterio di Sylvester è un teorema che fornisce una condizione necessaria e sufficiente affinché una matrice simmetrica sia definita positiva. Stabilisce che una matrice simmetrica è definita positiva se e solo se i determinanti di tutte le sottomatrici principali di testa  $A_k, k = 1, \dots, n$  sono **positivi**. Poiché la sottomatrice principale di testa di ordine 1 è l'elemento  $a_{11}$  e la sottomatrice principale di testa di ordine n coincide con la matrice A, segue che  $a_{11} > 0$  ed il determinante dell'Hessiano è positivo. Quindi il punto che annulla il gradiente è il minimo della forma quadratica.

Quindi il vettore  $x^*$  che minimizza la funzione  $F(x)$  coincide con la soluzione del sistema lineare (1); viceversa la soluzione del sistema (1) con matrice A simmetrica definita positiva minimizza la corrispondente funzione quadratica (2).

### Esempio $n=2$


$$A = \begin{bmatrix} 8 & 4 \\ 4 & 3 \end{bmatrix} \quad b = \begin{bmatrix} 8 \\ 10 \end{bmatrix} \quad x = \begin{bmatrix} -2 \\ 6 \end{bmatrix}$$

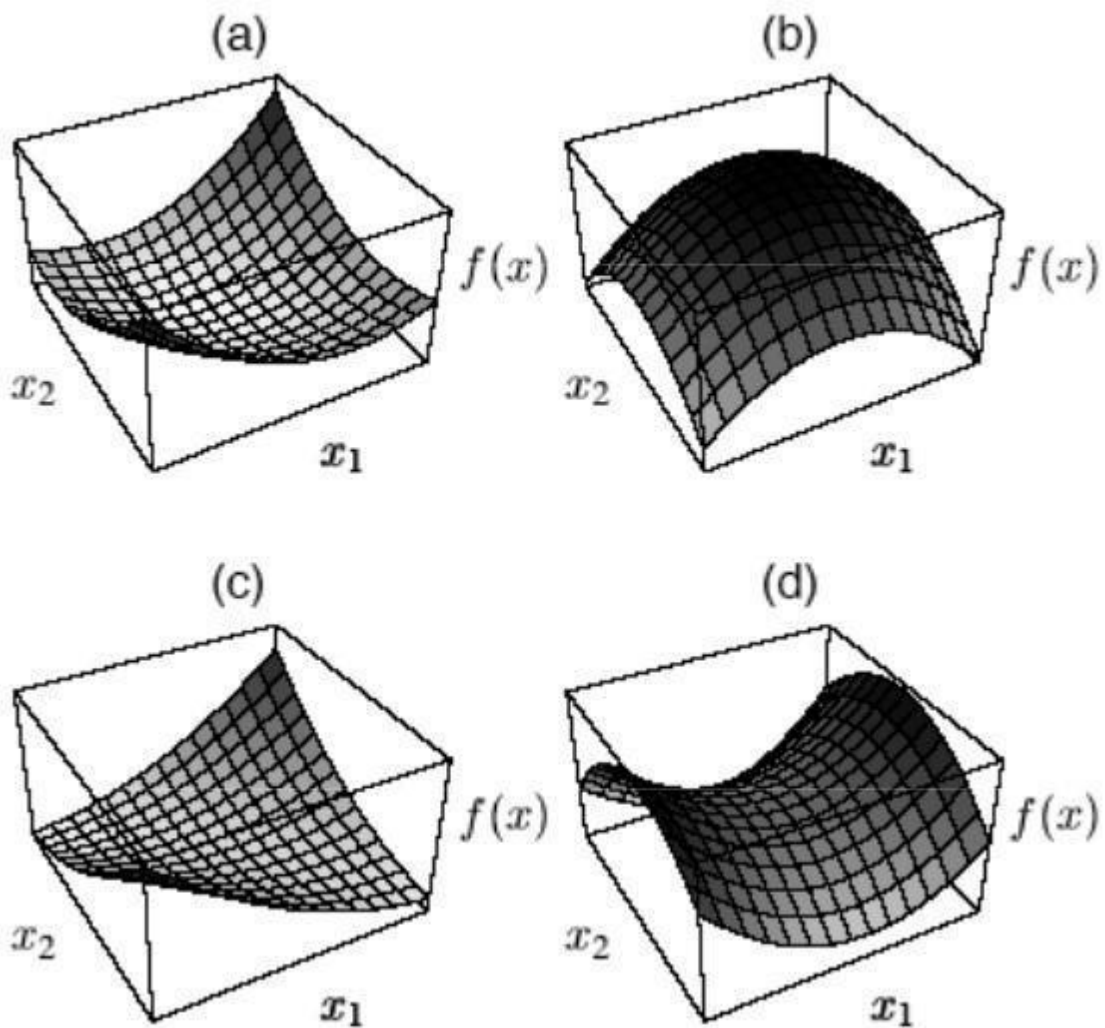
La matrice A è simmetrica e definita positiva.

Vale il seguente risultato: Forma quadratica associata ad una matrice simmetrica e definita positiva è strettamente convessa, quindi se ammette minimo, esso è unico

$$F(x_1, x_2) = \frac{1}{2}(a_{11}x_1^2 + 2a_{12}x_1x_2 + a_{22}x_2^2) - (b_1x_1 + b_2x_2)$$

### Grafico della forma quadratica associata al sistema lineare $Ax=b$





Se la matrice  $A$ , della forma quadratica è *definita positiva* allora il minimo corrisponde alla soluzione del sistema ; mentre se  $A$  è *definita negativa*, (b) in questo caso il paraboloide è rovesciato ed il suo massimo corrisponde alla soluzione del sistema; se invece  $A$  è *semidefinita positiva* , (c) allora vuol dire che almeno un suo autovalore è nullo e sarà perciò singolare, le soluzioni del sistema sono più di una e corrispondono all'insieme dei punti della linea sul fondo del paraboloide; infine se  $A$  è *non definita*, (d) la soluzione è un cosiddetto punto di sella.

Il risultato del teorema 1 ci permette di affermare che per **la risoluzione di sistemi lineari con matrice simmetrica definita positiva** in generale possono essere usati i metodi per determinare il minimo di una funzione quadratica, noti come **metodi di discesa**.

Questi metodi iterativi consistono nel determinare, a partire da un vettore  $x$  al passo  $k$ , che indicheremo con  $x^{(k)}$ , un vettore direzione  $p$  al passo  $k$ ,  $p^{(k)}$ , opportuno e nel correggere  $x^{(k)}$  in questa direzione in modo che il valore della funzione quadratica  $F$  nel nuovo iterato  $x^{(k+1)} = x^{(k)} + \alpha^{(k)}p^{(k)}$  diminuisca, cioè

$$F(x^{(k)} + \alpha^{(k)}p^{(k)}) < F(x^{(k)}).$$

Perché ciò avvenga il parametro  $\alpha^{(k)}$  e la direzione  $p^{(k)}$  devono essere scelti in modo opportuno. I differenti metodi di discesa sono caratterizzati dalla scelta della direzione di discesa  $p^{(k)}$  fra le direzioni di discesa ammissibili.

La determinazione del parametro  $\alpha^{(k)}$  che permette di rendere minima la  $F$  nella direzione  $p^{(k)}$  differenzia i metodi suddetti quando vengono impiegati per la soluzione del sistema lineare  $Ax = b$  (quindi in cui  $A$  sia nota) da quando vengono impiegati per determinare il minimo di una funzione qualsiasi (in cui quindi la matrice  $A$  non è nota).

### Un **generico algoritmo di discesa per la minimizzazione**

1. Parti con qualche  $x^{(0)}$ ,  $k = 0$

2. Determina la direzione di discesa  $p^{(k)}$

3. Scegli lo step-size  $\alpha^{(k)}$  tale che

$$F(x^{(k)} + \alpha^{(k)}p^{(k)}) < F(x^{(k)})$$

4. Aggiorna l'iterato

$$x^{(k+1)} = x^{(k)} + \alpha^{(k)}p^{(k)}$$

5. Incrementa il contatore  $k=k+1$

*Fino a convergenza*

## 2. Scelta dello step-size

Nel caso in cui la matrice  $A$  sia nota si vede infatti che

$$\begin{aligned} F(x^{(k)} + \alpha^{(k)} p^{(k)}) &= \frac{1}{2} \langle A(x^{(k)} + \alpha^{(k)} p^{(k)}), (x^{(k)} + \alpha^{(k)} p^{(k)}) \rangle - \\ &\quad \langle b, (x^{(k)} + \alpha^{(k)} p^{(k)}) \rangle \\ &= \frac{1}{2} \langle Ax^{(k)}, x^{(k)} \rangle + \alpha^{(k)} \langle Ax^{(k)}, p^{(k)} \rangle + \frac{1}{2} (\alpha^{(k)})^2 \langle Ap^{(k)}, p^{(k)} \rangle + \\ &\quad - \langle b, x^{(k)} \rangle - \alpha^{(k)} \langle b, p^{(k)} \rangle \\ &= F(x^{(k)}) + \frac{1}{2} (\alpha^{(k)})^2 \langle Ap^{(k)}, p^{(k)} \rangle + \alpha^{(k)} \langle r^{(k)}, p^{(k)} \rangle, \quad r^{(k)} = Ax^{(k)} - b, \end{aligned}$$

è una **funzione quadratica** in  $t$ .

Per determinarne il valore di  $t$  che rende minima  $F$  nella direzione  $p^{(k)}$ , cioè:

$$\arg \min_{\alpha^{(k)}} F(x^{(k)} + \alpha^{(k)} p^{(k)})$$

basta considerare

$$\frac{dF}{d\alpha^{(k)}} = \alpha^{(k)} \langle Ap^{(k)}, p^{(k)} \rangle + \langle r^{(k)}, p^{(k)} \rangle$$

e uguagliarla a 0; si ottiene per il parametro  $\alpha^{(k)}$  il valore

$$\alpha^{(k)} = - \frac{\langle r^{(k)}, p^{(k)} \rangle}{\langle Ap^{(k)}, p^{(k)} \rangle} = - \frac{(r^{(k)})^T p^{(k)}}{(p^{(k)})^T A p^{(k)}} \quad (3)$$

Questo significa che, una volta determinata la direzione  $p^{(k)}$ , ovvero scelto il metodo di minimizzazione, la relazione (3) ci fornisce il valore da assegnare allo stepsize  $\alpha^{(k)}$  per ottenere il minimo valore possibile della  $F$  lungo la direzione  $p^{(k)}$ .

**Osservazione:** il valore di  $\alpha^{(k)}$  fornito dalla (3) ci fornisce un minimo per  $F$  in quanto se effettuiamo la derivata seconda in  $t$  otteniamo

$$\frac{d^2 F}{dt^2} = \langle Ap^{(k)}, p^{(k)} \rangle$$



che è una quantità positiva per ogni direzione di  $p^{(k)}$ , essendo la matrice  $A$  per ipotesi simmetrica e definita positiva.

Nel caso in cui il metodo venga applicato per determinare il minimo di una funzione e quindi la matrice  $A$  non sia nota, il valore di  $t$  ottimale si ottiene risolvendo un problema di minimo monodimensionale per la funzione  $F(t)$ .

Nel punto di minimo ottenuto usando la formula (3) per il valore del parametro  $t$  abbiamo il seguente risultato:

### **Teorema:**

*Nel punto di minimo  $x^{(k+1)} = x^{(k)} + \alpha^{(k)} p^{(k)}$ , ottenuto muovendosi lungo la direzione  $p^{(k)}$  con  $\alpha^{(k)}$  dato dalla (3), il vettore residuo  $r^{(k+1)} = Ax^{(k+1)} - b$  risulta ortogonale alla direzione  $p^{(k)}$ , cioè*

$$\langle r^{(k+1)}, p^{(k)} \rangle = 0 \quad (*)$$

### **Dimostrazione:**

Essendo

$$r^{(k+1)} = Ax^{(k+1)} - b = A(x^{(k)} + \alpha^{(k)} p^{(k)}) - b = r^{(k)} + \alpha^{(k)} A p^{(k)}$$

Si ottiene

$$\langle r^{(k+1)}, p^{(k)} \rangle = \langle r^{(k)}, p^{(k)} \rangle + \alpha^{(k)} \langle A p^{(k)}, p^{(k)} \rangle$$

che risulta 0 scegliendo  $\alpha^{(k)}$  secondo la (3).

$$\langle r^{(k+1)}, p^{(k)} \rangle = \langle r^{(k)}, p^{(k)} \rangle - \frac{\langle r^{(k)}, p^{(k)} \rangle}{\langle A p^{(k)}, p^{(k)} \rangle} \langle A p^{(k)}, p^{(k)} \rangle = 0$$

### 3. Condizioni di ammissibilità per la direzione di discesa

Per quanto riguarda la scelta delle direzioni di discesa  $p^{(k)}$  se si considera la relazione

$$\alpha^{(k)} = - \frac{\langle r^{(k)}, p^{(k)} \rangle}{\langle \nabla F(x^{(k)}), p^{(k)} \rangle}$$

si può affermare che  $p^{(k)}$  non deve essere ortogonale al residuo  $r^{(k)}$ , o, in modo equivalente, (visto che il gradiente della forma quadratica calcolato in  $x^{(k)}$  è uguale al residuo del sistema lineare valutato in  $x^{(k)}$ ) non deve essere ortogonale al gradiente  $\nabla F(x^{(k)})$  di  $F$  perché questo porterebbe a  $\alpha^{(k)}=0$ .

Se inoltre consideriamo lo sviluppo in serie di Taylor della  $F(x^{(k)} + \alpha^{(k)}p^{(k)})$ , in un intorno di  $x^{(k)}$ , cioè

$$F(x^{(k+1)}) = F(x^{(k)} + \alpha^{(k)}p^{(k)}) = F(x^{(k)}) + \alpha^{(k)}\nabla F(x^{(k)})^T p^{(k)} + \dots$$

che si può scrivere come

$$F(x^{(k+1)}) = F(x^{(k)} + \alpha^{(k)}p^{(k)}) = F(x^{(k)}) + \alpha^{(k)} \langle \nabla F(x^{(k)}), p^{(k)} \rangle + \dots$$

e richiediamo che si abbia

$$F(x^{(k)} + \alpha^{(k)}p^{(k)}) < F(x^{(k)}) \quad \text{per } \alpha^{(k)} > 0, \quad (4)$$

allora la direzione  $p^{(k)}$  deve soddisfare la seguente condizione

$$\langle \nabla F(x^{(k)}), p^{(k)} \rangle < 0$$


che rappresenta la condizione di **direzione ammissibile**.

Questa condizione ci dice che l'angolo fra la nuova direzione di discesa e il gradiente  $\nabla F(x^{(k)})$  deve avere coseno negativo (ricordiamo che  $\langle \nabla F(x^{(k)}), p^{(k)} \rangle = \|\nabla F(x^{(k)})\| \cdot \|p^{(k)}\| \cos \theta$  dove l'angolo  $\theta$  è l'angolo fra i due vettori) cioè l'angolo  $\theta$  deve essere maggiore di  $\pi/2$  e minore di  $3\pi/2$ .

Poiché la condizione di ammissibilità per la direzione di discesa è data in funzione del gradiente della  $F(x)$  i metodi di discesa vengono anche chiamati metodi del gradiente.

### **Es: Interpretazione geometrica dei metodi di discesa**

Nel caso  $n = 2$  la funzione  $F(x)=\text{cost}$  è rappresentata da ellissi concentriche il cui centro coincide con il minimo della funzione quadratica  $F(x)$  e costituisce la soluzione del problema. Il seguente grafico mostra quanto affermato dalla condizione di ammissibilità per la direzione di discesa.



### **4. Metodo della Discesa più Ripida (Steepest Descent)**

Il metodo di Discesa più Ripida (Steepest Descent) è caratterizzato dalla scelta, ad ogni passo  $k$ , della direzione  $p^{(k)}$  come l'antigradiente della  $F$  calcolato nell'iterato  $k$ -esimo, ovvero

$$p^{(k)} = -\nabla F(x^{(k)}) = -Ax^{(k)} + b = -r^{(k)}. \quad (5)$$

Poiché il gradiente è la direzione di massima crescita, questo significa che ad ogni passo il vettore  $p^{(k)}$  essendo l'antigradiente di  $F$  coincide con la direzione di massima decrescita.

In questo caso la (3) diventa

$$\alpha^{(k)} = - \frac{\langle r^{(k)}, p^{(k)} \rangle}{\langle A p^{(k)}, p^{(k)} \rangle} = \frac{\langle r^{(k)}, r^{(k)} \rangle}{\langle A r^{(k)}, r^{(k)} \rangle}$$

e

$$x^{(k+1)} = x^{(k)} + \alpha^{(k)} p^{(k)}.$$

### Algoritmo steepest descent (Algoritmo del gradiente)

1. Parti con qualche  $x^{(0)}$ ,  $k = 0$

→ 2. Calcola la direzione di discesa più ripida

$$p^{(k)} = -\nabla f(x^{(k)})$$

3. Scegli lo stepsize  $\alpha^{(k)}$  tale che

$$F(x^k + \alpha^{(k)} p^{(k)}) < F(x^{(k)})$$

$$\alpha^{(k)} = \frac{\langle r^{(k)}, r^{(k)} \rangle}{\langle A r^{(k)}, r^{(k)} \rangle}$$

4. Aggiorna l'iterato

$$x^{(k+1)} = x^{(k)} + \alpha^{(k)} p^{(k)}$$

$$r^{(k+1)} = r^{(k)} + \alpha^{(k)} A p^{(k)}$$

5. Incrementa il contatore  $k=k+1$

**Fino a convergenza**

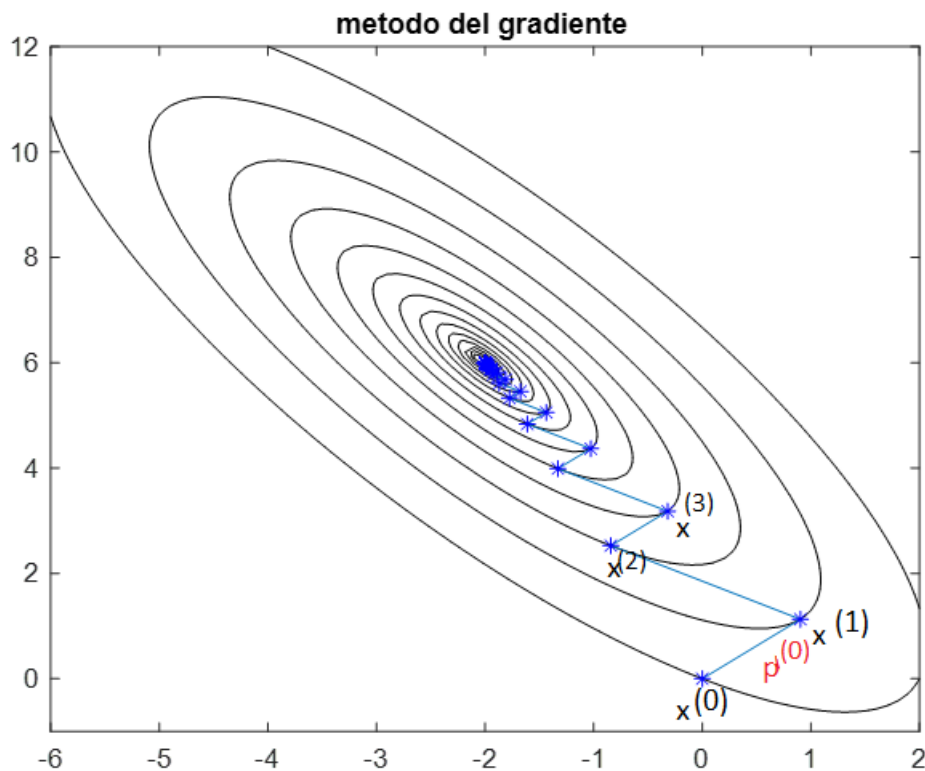
Si considera che il procedimento iterativo ha raggiunto la convergenza quando

$$\frac{\|r^{(k+1)}\|_2}{\|b\|} \leq \text{tolleranza}$$

### Esempio

$$A = \begin{bmatrix} 8 & 4 \\ 4 & 3 \end{bmatrix} \quad b = \begin{bmatrix} 8 \\ 10 \end{bmatrix} \quad x = \begin{bmatrix} -2 \\ 6 \end{bmatrix}$$

Iterato iniziale  $x^{(0)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$



La direzione  $p^{(0)}$  è opposta alla direzione del gradiente alla curva di livello  $F(x^{(0)}) = \text{cost}$  nel punto  $x^{(0)}$  (Ricordiamo che il gradiente  $\nabla F(x^{(0)}) = r^{(0)}$  è perpendicolare alla tangente alla curva di livello nel punto  $x^{(0)}$ ).

L'iterato  $x^{(1)}$  si trova a partire da  $x^{(0)}$  nella direzione di  $p^{(0)}$  nella posizione individuata da  $\alpha^{(1)}$ ,  $x^{(1)} = x^{(0)} + \alpha^{(1)}p^{(0)}$ .

Dal grafico si **nota carattere a zigzag** del metodo del gradiente, dovuto al fatto che il gradiente di una iterata è ortogonale al gradiente di quello precedente. Si noterà che,

nonostante la convergenza dell'algoritmo, quest'ultimo è relativamente lento a causa di questo avanzamento a zig zag.

## Velocità di Convergenza

La velocità di convergenza di un metodo iterativo si può misurare considerando di quanto si è ridotto l'errore iniziale alla k-esima iterazione .

Per misurare l'errore si definisce la norma indotta dalla matrice simmetrica definita positiva A su x come

$$\|x\|_A^2 = x^T A x.$$

Per il **metodo del gradiente Steepest Descent** vale la seguente relazione

$$\|x^{(k)} - x^*\|_A \leq \left( \frac{K(A) - 1}{K(A) + 1} \right)^k \cdot \|x^{(0)} - x^*\|_A$$

Pertanto, definendo l'errore al passo k

$$e_A^{(k)} = \|x^{(k)} - x^*\|_A$$

si ha

$$e_A^{(k)} \leq \left( \frac{K(A) - 1}{K(A) + 1} \right)^k \cdot e_A^{(0)}$$

dove  $K(A)$  è l'indice di condizionamento di A, dato da  $K(A) = \|A\| \cdot \|A^{-1}\| = \lambda_{\max}/\lambda_{\min}$ .

Tanto più  $K(A)$  è alto tanto più il rapporto  $\left( \frac{K(A) - 1}{K(A) + 1} \right) \approx 1$  e quindi tanto più è lenta la convergenza.

Poiché la funzione quadratica  $F(x)$  data dalla (2) assegnata la  $F(x) = \text{cost}$  rappresenta

l'espressione di un iperellissoide con eccentricità legata dal rapporto  $\frac{\lambda_{\max}}{\lambda_{\min}}$ , possiamo

dire che ad una matrice  $A$  mal condizionata corrisponde un' iperellissoide molto allungato, mentre ad un  $K(A)$  piccolo corrisponde un iperellissoide più arrotondato.